01 Tools

2026-10-22

Worum es heute geht

- **Theorie**:
  - → Grundprinzipien der Datenarbeit (Zeit- und Projektplanung)
  - → Datenquellen, Lizenzen & Open Data
- **Praxis**:
  - → Tabellarische Dateiformate in Tabellenkalkulation laden und aufbereiten
  - → Fragen an einen Datensatz entwickeln
  - → Tabelle aus PDF extrahieren
- **Technik**:
  - → Dateiformate: csv, Tabellen in PDF
  - → Tools: LibreOffice, Datawrapper, Tabula, Developertools
- **Daten**:
  - → Hundebiss-Statistik Berlin & Rheinland-Pfalz

Beispiel: “Wie Europa seinen Solarboom finanziert”



von Kira Schacht / Deutsche Welle 🔗 Deutsch 🔗 English

Fragen zum Lesen:

1. Was gefällt dir (nicht)? Warum?
2. Was interessiert dich? Was langweilt dich?
3. Wenn du fertig bist: Was ist hängen geblieben?

Storytelling – Die Grundlagen

1. Was ist eine Geschichte?

“Eine Geschichte besteht in aller Regel aus drei Basis-Elementen: eine aktiv-handelnde Person, ein konkretes Ziel und (etliche) Widerstände.

1. Was ist eine Geschichte?

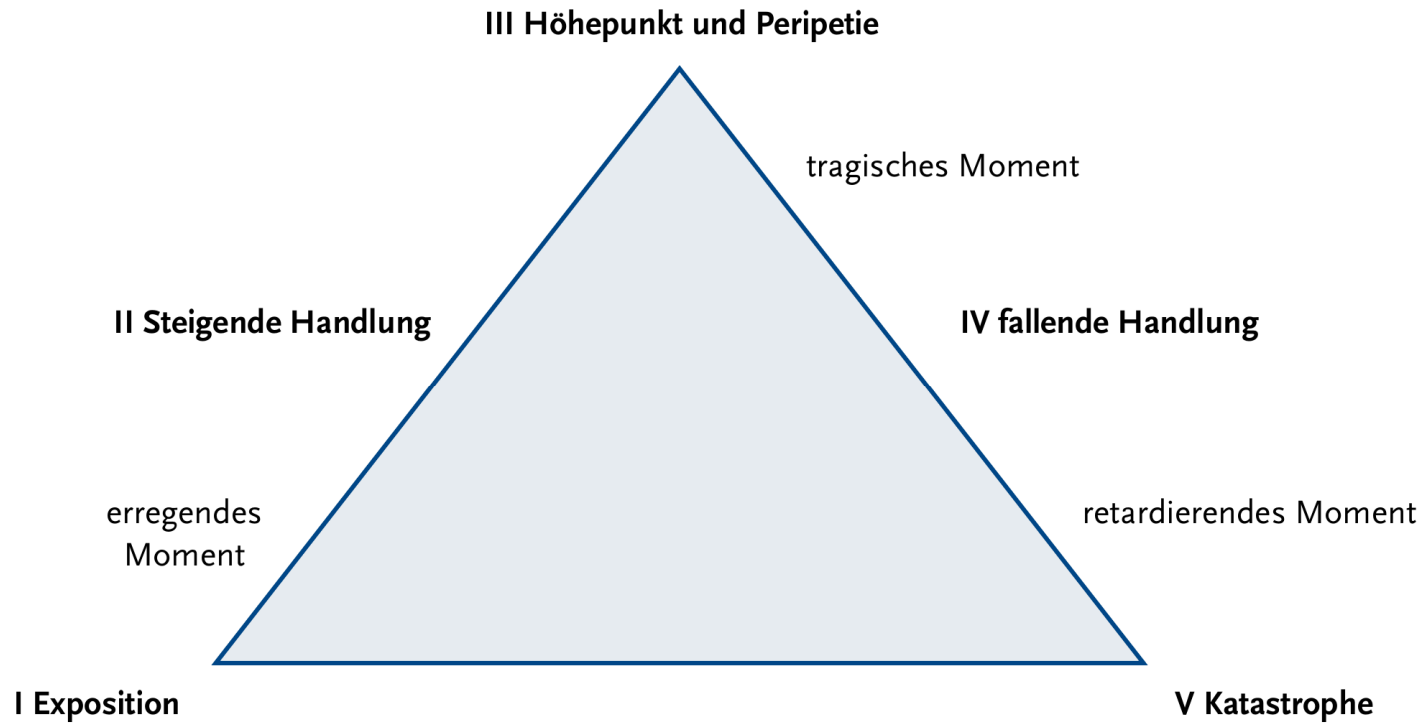


Abb. 6: Dramenstruktur nach Freytag

1. Was ist eine Geschichte?

Quelle: Friedmann Harzer: “Literarische texte interpretieren : Lyrik - Prosa - Drama”, S. 197

1. Was ist eine Geschichte?

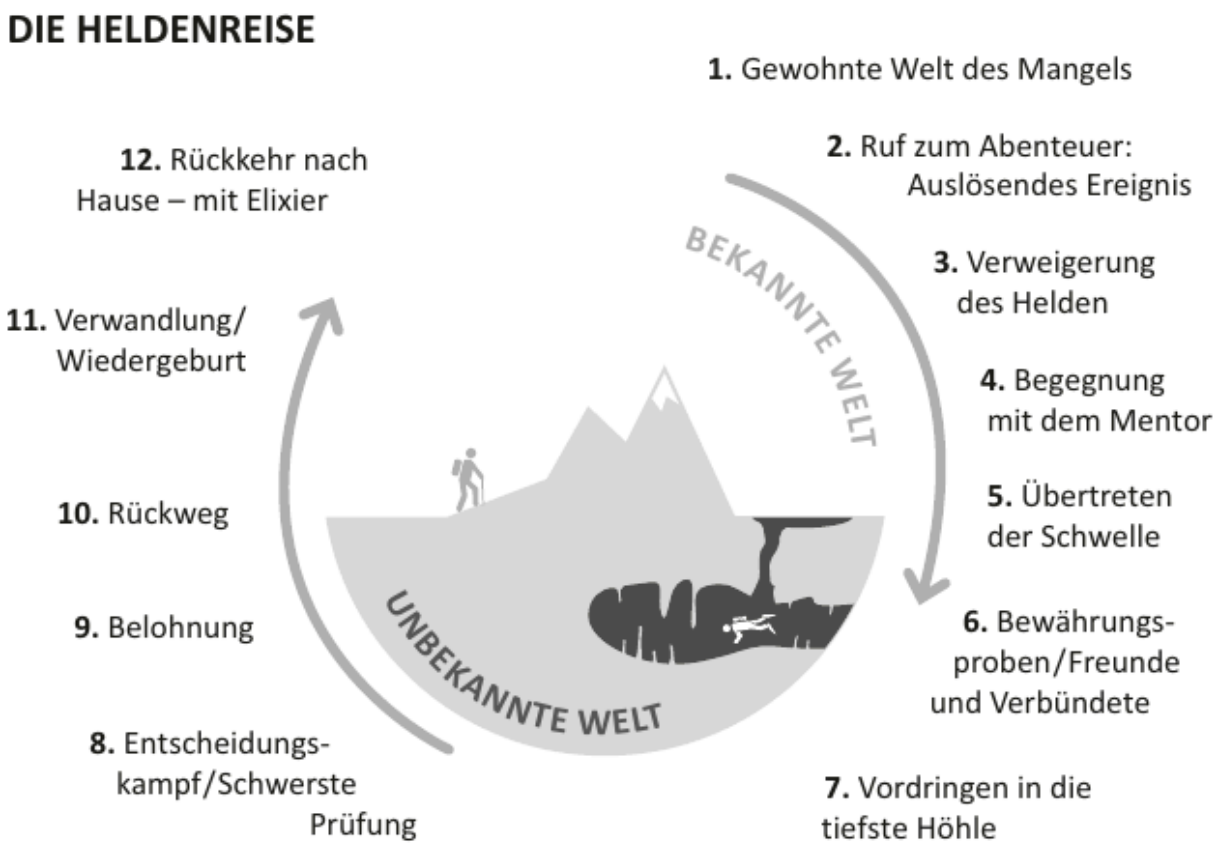


Abb. 3.2 Die Heldenreise (eigene Darstellung)

1. Was ist eine Geschichte?

Quelle: Sven Preger: “Storytelling”, S. 74

> “A (der Protagonist) will B (seine Absicht/sein Ziel), weil er C (die Motivation), stößt aber auf D (Hindernisse). Diese Hindernisse muss der Protagonist überwinden, oder es zumindest versuchen. Der Erzählsatz ist damit der Kompass, an dem sich die Geschichte ausrichtet.”

2. Was ist eine Nachricht?

Eine Nachricht sollte möglichst viele der sieben wichten Fragen beantworten – diese können wir verwenden, um Fragen an unsere Daten zu entwickeln:

- **Wer?** *(Wer hat am meisten…? Wer hat am wenigsten…?)*
- **Was?** *(Was ist anders als vielleicht angenommen?)*
- **Wo?** *(Wo häufen sich die Ereignisse?)*
- **Wann?** *(Wann hat sich etwas verändert? Wie hat sich etwas entwickelt?)*
- **Wie?** *(Wie hängen x und y zusammen?)*
- (**Warum?**)
- **Woher?** *(Woher kommen die Daten? Wer hat sie mit welchem Interesse erhoben?)*

(siehe Einführung in den praktischen Journalismus)

2. Was ist eine Nachricht?

Praktische Probe, ob eine Nachricht relevant ist

Der “Küchenzuruf”: Eine Zusammenfassung der zentralen Aussage in maximal zwei Sätzen. Der Begriff wurde vom Stern-Redakteur Henri Nannen geprägt und durch eine beispielhafte Situation erklärt, in der ein gewisser Hans im Esszimmer den ‚Stern‘ liest, während „Frau Grete“ in der Küche „sich die Schürze umbindet, um sich für den Abwasch vorzubereiten“. Nach „beendigter Lektüre“ ruft Hans seiner Grete in die Küche zu: „Mensch Grete, die in Bonn spinnen komplett! Die wollen schon wieder die Steuern erhöhen!“

Das würde man heute hoffentlich anders erklären, aber das Prinzip bleibt das gleiche:

“Hey, hast du schon gehört? ...!”

Grundprinzipien der Datenarbeit



1. **Wir verändern niemals Originaldaten.**
2. Wir arbeiten möglichst **nachvollziehbar**, also möglichst nah am Original.
3. Wir **dokumentieren** unsere Arbeitsschritte, um sie reproduzieren zu können.

→ Wir rechnen also mit Fehlern und arbeiten so, dass wir sie finden und korrigieren können.

Das Ding mit der Objektivität...

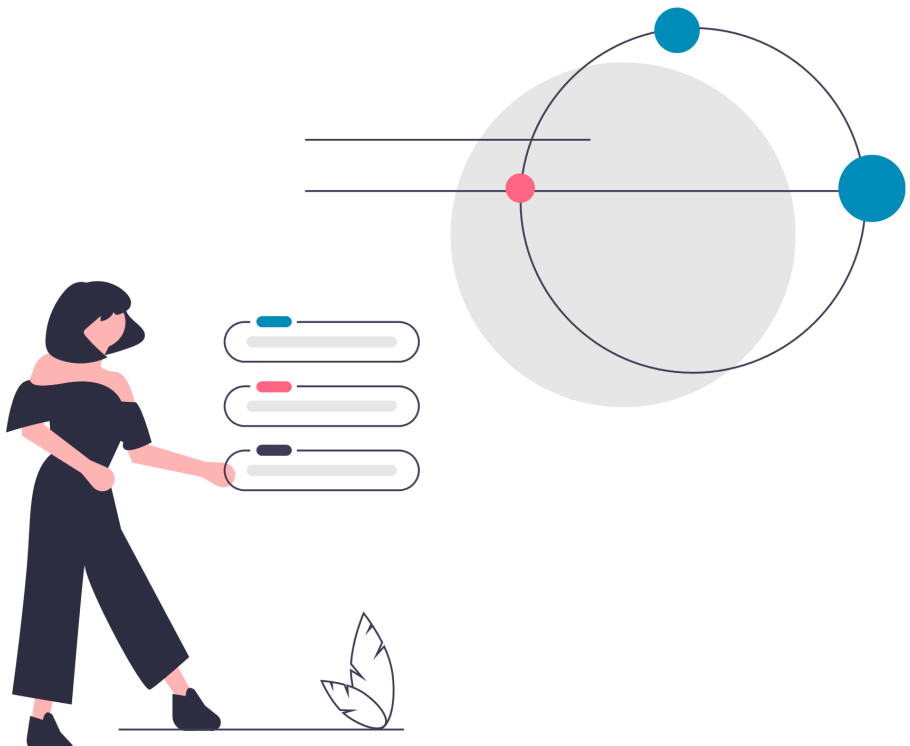
Leitlinien

Es gibt viele allgemein akzeptierte Regeln für zuverlässige Recherche. Hier sind ein paar:

- Bemühe dich, alle relevanten Quellen zu finden.
- Lasse keine Quelle unter den Tisch fallen, nur weil sie etwas anderes behauptet, als du dir erhofft hast.
- Mache deinen Quellen transparent.
- Zitiere korrekt und ohne Aussagen aus dem Kontext zu reißen.
- Formuliere deine Erkenntnisse so deutlich und konkret wie möglich.
- Weise ehrlich darauf hin, was du nicht herausfinden konntest.
- Lasse einen unabhängigen Experten über deine Arbeit schauen, bevor du sie publizierst.

[1, S. 20f]

Wie plane ich ein Datenprojekt?



Beispielablauf

0. **Idee:** Irgendjemand hat eine Idee…
1. **Datenrecherche**: Welche Daten gibt es?
2. **Quellenkritik**: Was können die Daten sagen, was nicht?
3. **Hypothesen finden**: “Drehbuch der Recherche”
4. **Daten analysieren**: Hypothesen prüfen
5. **Daten einordnen lassen**: Expert*innen suchen, Interviews und Hintergrundgespräche führen
6. **Veröffentlichung planen**: Grafiken entwerfen, texten
7. **Ergebnisse verifizieren**: mindestens 4-Augen-Check

🏋️ Übung: Hundebiss-Statistik Berlin 2024



“Gestern hat ein Hund einen Menschen schwer verletzt. Passiert sowas eigentlich öfter?”

1. 🔍 **Datenrecherche**: Welche Daten gibt es?

Suchtipps anzeigen

- Suchmaschine → Website Berlin
- govdata.de → Datensatz zum Download

Wir mögen CSV-Dateien

- größter Vorteil: klein
- sehr schlicht, können eigentlich alle Programme öffnen
- Nachteil: speichern keinen Kontext

2. 📐 **Quellenkritik**: Was können die Daten sagen, was nicht?

- Was sind die aktuellsten verfügbaren Daten – in welchen Zyklen werden frische Daten veröffentlicht?
- Könnte es ein, dass bis zur geplanten Veröffentlichung aktualisierte Daten bereitstehen?
- Wie zuverlässig sind die Daten – kommen sie möglichst direkt von der Erhebungsstelle?
- Was wissen wir über die Daten – gibt es Kontext-Informationen?

3. 🤔 **Hypothesen finden**: “Drehbuch der Recherche”

- Welche Hunde haben die meisten Menschen verletzt?
- Welche Hunde haben im Verhältnis zu allen Menschen, die sie verletzt haben, die meisten Menschen *schwer* verletzt?
- Welche Hunde, die nicht als gefährlich gelten, haben mehr Menschen verletzt, als solche, die als gefährlich gelten?

4. 🛠️ **Daten analysieren**: Hypothesen prüfen

- Hier: Summen bilden, Anteile ausrechnen

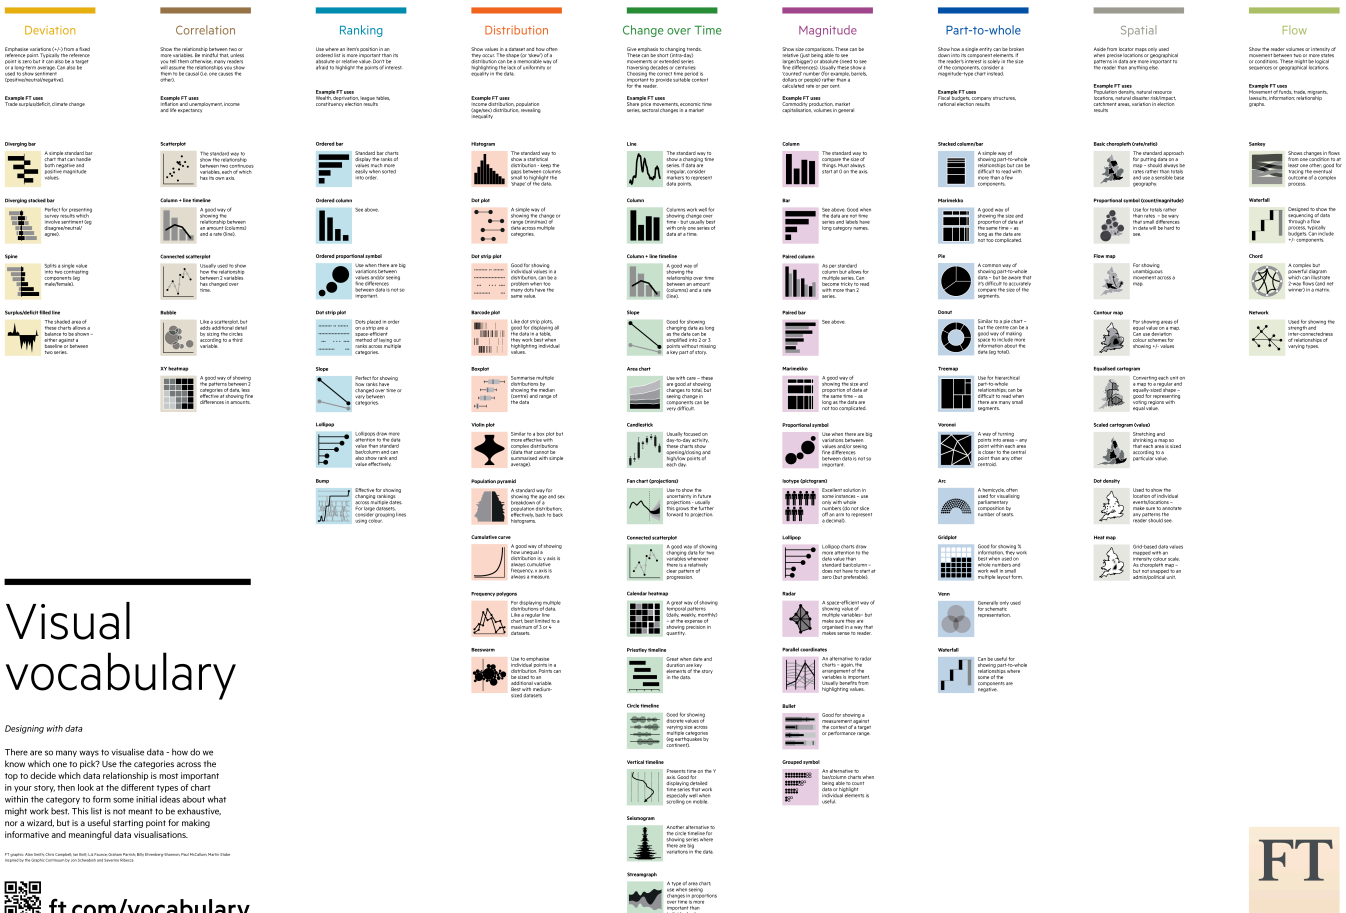
5. 💬 **Daten einordnen lassen**: Interviews & Hintergrund

- Gibt es einen Kontakt zur datenveröffentlichenden Stelle – wer ist fachlich zuständig?
- Welche Expert*innen beschäftigen sich noch mit den Daten und können in einem Hintergrundgespräch die Methodik einordnen?

6. ✍️ **Veröffentlichung planen**: Grafiken entwerfen, texten

- Was ist interessant?
- Die richtige Grafik zur Aussage finden:

6. ✍️ **Veröffentlichung planen**: Grafiken entwerfen, texten



6. ✍️ **Veröffentlichung planen**: Grafiken entwerfen, texten

- → 🔗 *The* Visual Vocabulary, developed and published by Financial Times (FT)
- → 🔗 Datawrapper: “A friendly guide to choosing a chart type”
- → 🔗 Storytelling with Data: “SWD Chart Guide”

- Empfehlung für Visualisierungen: Datawrapper

7. 👀 **Ergebnisse verifizieren**: mindestens 4-Augen-Check

- Aussagen auf Plausibilität prüfen
- dokumentierte Schritte nachvollziehen

Wie lange dauert’s denn nun?

Inoffizielle Faustregel 😉: Doppelt so lange, wie du denkst + 1 Tag.

Datenquellen



- Statistisches Bundesamt
- Statistische Landesämter
- govdata.de – Daten von Behörden, Kommunen, etc.

- Drucksachen Bundestag
- Google Dataset Search

Welche Daten dürfen wir benutzen?

> “Open means anyone can freely access, use, modify, and share for any purpose (subject, at most, to requirements that preserve provenance and openness).”
>
> https://opendefinition.org/

- “Gemeinfreiheit” CCO
- CC BY 4.0
- “Datenlizenz Deutschland” BY, Zero

govdata.de rät zu CC-Lizenzen

🏋️ Übung: Hundebiss-Statistik Rheinland-Pfalz 2024

Suchtipps anzeigen

- Google-Suche: “innenministerium rheinland pfalz hund filetype:pdf 2024”
- 🔗

Beispiel-Bericht anzeigen “Zahl der Verletzten durch Hundebisse in Berlin zurückgegangen” rbb24.de

Tools, um Tabellen aus PDFs zu extrahieren

- tabula Download oder gehostet (**öffentlich!!**)
- mit der Programmiersprache Python: camelot / excalibur
- für komplexere Dokumente, Python-Kenntnisse nötig: docling

Wie finde ich Tools?

- **alternativeto.net**: Einstellungen: “Open Source” + eigenes Betriebssystem
- **github.com**: Code-Plattform (gehört Microsoft), die kuratierte “awesome”-Listen hat, z.B. https://github.com/topics/awesome-list
- abgucken bei anderen:
  - → Deutsche Welle Datenteam,
  - → Bayerische Digitalagentur Byte Bayern
  - → 30DayMapChallenge, 30DayChartChallenge

🏋️ Übung: Hundebiss-Statistik Berlin über die Jahre



Wir erinnern uns: Auf govdata.de gab es Datensätze bis 2016 zurück...

Herausforderungen: - wir müssen die alle runterladen (= scraping) - idealerweise brauchen wir das in einer Datei (= coding)

Schritt 1: Links zu csv-Dateien sammeln

- Browser öffnen + Developer-Tools ausklappen (Win/Linux: Ctrl + Shift + I or F12; macOS: Cmd + Opt + I)
- Ganz links in der Ecke auf das Icon mit Rechteck und Cursor klicken (Win/Linux: Ctrl + Shift + C; macOS: Cmd + Opt + C)
- jetzt zu einem csv-Button navigieren und anklicken

Schritt 3: R installieren

R-Download

Schritt 4: RStudio installieren

RStudio-Download

Schritt 5: R-Projekt anlegen

Empfehlung für eine Ordnerstruktur:

```
├── code
├── data
│   ├── raw
│   ├── helpers
│   ├── processed
│   └── final
└── report
    ├── img
    └── docs
```

anlegen:

1. Anwendung “Terminal” suchen → öffnen
2. ein paar Befehle ausprobieren:

Schritt 5: R-Projekt anlegen

- `ls -l` listet alle Ordner und Dateien auf, mit ein paar Metadaten
- `cd /hier/ein/pfad/zum/ordner` springt zu einem Ordner
- `pwd` zeigt an, in welchem Ordner man sich gerade befindet
- alle Ordner wie oben anlegen: 🪄

```
mkdir -p code data/raw data/helpers data/processed data/final report/img report/docs
```

Schritt 6: Code kopieren, ausführen, glücklich werden

Code anzeigen

```
# load libraries
library(stringr)

# read html
html <- read_html("https://www.govdata.de/suche/daten/hundebiss-statistik-berlin")

# extract all links
links <- html |>
  html_elements("a") |>
  html_attr("href")

# filter links if they end with ".csv"
csv_links <- links[str_detect(links, ".csv$")]
```

Schritt 6: Code kopieren, ausführen, glücklich werden

```
# download all csv files
for (u in csv_links) {
  download.file(u, file.path(here::here("data/raw"), basename(u)))
}
```

Langeweile?

Weiterlesen / -hören

- Storytelling:
  - → Sven Preger (2024): “Geschichten erzählen : Storytelling für Radio und Podcast”
  - → BR kontrovers (2025): “Bauen im Überschwemmungsgebiet, Unterwegs mit der Dorfpolizei und mehr”
- Datenjournalismus:
  - → Christina Elmer, Lorenz Matzat (Hrsg.): “Handbuch Daten und KI im Journalismus”
- Journalismus allgemein:
  - → Gabriele Hooffacker, Klaus Meier (2026): “La Roches Einführung in den praktischen Journalismus”
  - → Maria Ressa (2022): “How to stand up to a dictator”
  - → Podcast: Anja Reschke im Hotel Matze (2025): “Welche Aufgabe hat der Journalismus”

Ausprobieren

- immer nett: Was waren die häufigsten Vornamen, z.B. in Rostock oder Berlin

[1] L. Sengers and M. L. Hunter, *Drehbuch der Recherche: das verborgene Szenario: journalistische Recherchen planen und organisieren*, no. 25. in Nr-Werkstatt. Berlin: Netzwerk Recherche, 2018.