02 Daten

2026-10-29

Wie lange dauert’s denn nun?

Inoffizielle Faustregel 😉: Doppelt so lange, wie du denkst + 1 Tag.

Datenquellen



- Statistisches Bundesamt
- Statistische Landesämter
- govdata.de – Daten von Behörden, Kommunen, etc.

- Drucksachen Bundestag
- Google Dataset Search

Welche Daten dürfen wir benutzen?

> “Open means anyone can freely access, use, modify, and share for any purpose (subject, at most, to requirements that preserve provenance and openness).”
>
> https://opendefinition.org/

- “Gemeinfreiheit” CCO
- CC BY 4.0
- “Datenlizenz Deutschland” BY, Zero

govdata.de rät zu CC-Lizenzen

🏋️ Übung: Hundebiss-Statistik Rheinland-Pfalz 2024

Suchtipps anzeigen

- Google-Suche: “innenministerium rheinland pfalz hund filetype:pdf 2024”
- 🔗

Beispiel-Bericht anzeigen “Zahl der Verletzten durch Hundebisse in Berlin zurückgegangen” rbb24.de

Tools, um Tabellen aus PDFs zu extrahieren

- tabula Download oder gehostet (**öffentlich!!**)
- mit der Programmiersprache Python: camelot / excalibur
- für komplexere Dokumente, Python-Kenntnisse nötig: docling

Wie finde ich Tools?

- **alternativeto.net**: Einstellungen: “Open Source” + eigenes Betriebssystem
- **github.com**: Code-Plattform (gehört Microsoft), die kuratierte “awesome”-Listen hat, z.B. https://github.com/topics/awesome-list
- abgucken bei anderen:
  - → Deutsche Welle Datenteam,
  - → Bayerische Digitalagentur Byte Bayern
  - → 30DayMapChallenge, 30DayChartChallenge

🏋️ Übung: Hundebiss-Statistik Berlin über die Jahre



Wir erinnern uns: Auf govdata.de gab es Datensätze bis 2016 zurück...

Herausforderungen: - wir müssen die alle runterladen (= scraping) - idealerweise brauchen wir das in einer Datei (= coding)

Schritt 1: Links zu csv-Dateien sammeln

- Browser öffnen + Developer-Tools ausklappen (Win/Linux: Ctrl + Shift + I or F12; macOS: Cmd + Opt + I)
- Ganz links in der Ecke auf das Icon mit Rechteck und Cursor klicken (Win/Linux: Ctrl + Shift + C; macOS: Cmd + Opt + C)
- jetzt zu einem csv-Button navigieren und anklicken

Schritt 3: R installieren

R-Download

Schritt 4: RStudio installieren

RStudio-Download

Schritt 5: R-Projekt anlegen

Empfehlung für eine Ordnerstruktur:

```
├── code
├── data
│   ├── raw
│   ├── helpers
│   ├── processed
│   └── final
└── report
    ├── img
    └── docs
```

anlegen:

1. Anwendung “Terminal” suchen → öffnen
2. ein paar Befehle ausprobieren:

Schritt 5: R-Projekt anlegen

- `ls -l` listet alle Ordner und Dateien auf, mit ein paar Metadaten
- `cd /hier/ein/pfad/zum/ordner` springt zu einem Ordner
- `pwd` zeigt an, in welchem Ordner man sich gerade befindet
- alle Ordner wie oben anlegen: 🪄

```
mkdir -p code data/raw data/helpers data/processed data/final report/img report/docs
```

Schritt 6: Code kopieren, ausführen, glücklich werden

Code anzeigen

```
# load libraries
library(stringr)

# read html
html <- read_html("https://www.govdata.de/suche/daten/hundebiss-statistik-berlin")

# extract all links
links <- html |>
  html_elements("a") |>
  html_attr("href")

# filter links if they end with ".csv"
csv_links <- links[str_detect(links, ".csv$")]
```

Schritt 6: Code kopieren, ausführen, glücklich werden

```
# download all csv files
for (u in csv_links) {
  download.file(u, file.path(here::here("data/raw"), basename(u)))
}
```