02 Data

2026-10-29

Worum es heute geht

- **Theorie**:
  - → Wiederholung Grundprinzipien der Datenarbeit (Zeit- und Projektplanung)
  - → Datenquellen, Lizenzen & Open Data
- **Praxis**:
  - → Tabelle aus PDF extrahieren
- **Technik**:
  - → Dateiformate: Tabellen in PDF & html
  - → Tools: Tabula, Developertools
- **Daten**:
  - → Hundebiss-Statistik Berlin & Rheinland-Pfalz :::

Beispiel: “Warum sich immer mehr Menschen krankmelden”

von Sophie Menner, Julia Barthel, Kirsten Girschick, Josef Schön

br24.de / tagesschau.de



Wie lange dauert’s denn nun?

Inoffizielle Faustregel 😉: Doppelt so lange, wie du denkst + 1 Tag.

Datenquellen



- Statistisches Bundesamt
- Statistische Landesämter
- govdata.de – Daten von Behörden, Kommunen, etc.

- Drucksachen Bundestag
- Google Dataset Search

Wo kann man nach Daten stöbern?



- “Data Is Plural”, leider eingestellter Podcast + Newsletter, Archiv

- GitHub, z.B. Suche nach “awesome dataset”
- TidyTuesday, wöchentliche Challenge, die sich vor allem auf R bezieht
- kaggle as as very popular platform for data science (but I don’t like it, to me it seems often a bit... contextless?)
- reddit
- Our World in Data
- international / Ländervergleich: generell UN-Daten
  - → Weltgesundheitsorganisation WHO
  - → Humanitäre Daten der UN-Organisation OCHA

Welche Daten dürfen wir benutzen?

> “Open means anyone can freely access, use, modify, and share for any purpose (subject, at most, to requirements that preserve provenance and openness).”
>
> https://opendefinition.org/

- “Gemeinfreiheit” CCO
- CC BY 4.0
- “Datenlizenz Deutschland” BY, Zero

govdata.de rät zu CC-Lizenzen

🏋️ Übung: Hundebiss-Statistik Rheinland-Pfalz 2024

Suchtipps anzeigen

- Google-Suche: “innenministerium rheinland pfalz hund filetype:pdf 2024”
- 🔗

Beispiel-Bericht anzeigen “Zahl der Verletzten durch Hundebisse in Berlin zurückgegangen” rbb24.de

Tools, um Tabellen aus PDFs zu extrahieren

- tabula Download oder gehostet (**öffentlich!!**)
- mit der Programmiersprache Python: camelot / excalibur
- für komplexere Dokumente, Python-Kenntnisse nötig: docling

Wie finde ich Tools?

- **alternativeto.net**: Einstellungen: “Open Source” + eigenes Betriebssystem
- **github.com**: Code-Plattform (gehört Microsoft), die kuratierte “awesome”-Listen hat, z.B. https://github.com/topics/awesome-list
- abgucken bei anderen:
  - → Deutsche Welle Datenteam,
  - → Bayerische Digitalagentur Byte Bayern
  - → 30DayMapChallenge, 30DayChartChallenge

🏋️ Übung: Hundebiss-Statistik Berlin über die Jahre



Wir erinnern uns: Auf govdata.de gab es Datensätze bis 2016 zurück...

Herausforderungen: - wir müssen die alle runterladen (= scraping) - idealerweise brauchen wir das in einer Datei (= coding)

Schritt 1: Links zu csv-Dateien sammeln

- Browser öffnen + Developer-Tools ausklappen (Win/Linux: Ctrl + Shift + I or F12; macOS: Cmd + Opt + I)
- Ganz links in der Ecke auf das Icon mit Rechteck und Cursor klicken (Win/Linux: Ctrl + Shift + C; macOS: Cmd + Opt + C)
- jetzt zu einem csv-Button navigieren und anklicken

Schritt 3: R installieren

R-Download

Schritt 4: RStudio installieren

RStudio-Download

Schritt 5: R-Projekt anlegen

Empfehlung für eine Ordnerstruktur:

```
├── code
├── data
│   ├── raw
│   ├── helpers
│   ├── processed
│   └── final
└── report
    ├── img
    └── docs
```

anlegen:

1. Anwendung “Terminal” suchen → öffnen
2. ein paar Befehle ausprobieren:

Schritt 5: R-Projekt anlegen

- `ls -l` listet alle Ordner und Dateien auf, mit ein paar Metadaten
- `cd /hier/ein/pfad/zum/ordner` springt zu einem Ordner
- `pwd` zeigt an, in welchem Ordner man sich gerade befindet
- alle Ordner wie oben anlegen: 🪄

```
mkdir -p code data/raw data/helpers data/processed data/final report/img report/docs
```

Schritt 6: Code kopieren, ausführen, glücklich werden

Code anzeigen

```
# load libraries
library(stringr)

# read html
html <- read_html("https://www.govdata.de/suche/daten/hundebiss-statistik-berlin")

# extract all links
links <- html |>
  html_elements("a") |>
  html_attr("href")

# filter links if they end with ".csv"
csv_links <- links[str_detect(links, ".csv$")]
```

Schritt 6: Code kopieren, ausführen, glücklich werden

```
# download all csv files
for (u in csv_links) {
  download.file(u, file.path(here::here("data/raw"), basename(u)))
}
```

Übung: Musik – US-Charts

Seit 1958 veröffentlicht das US-Magazin “Billboard” jeden Dienstag die “beliebtesten” Songs – basierend auf Verkäufen, Airplay und Streaming der jeweiligen Erfassungswoche. Alle Top-Titel hat Chris Dalla Riva für seinen Blog und sein Buch zusammengetragen und freundlicherweise als Google-Tabelle veröffentlicht: Billboard Hot 100 Number Ones Database.

→ **Welche Geschichten lassen sich darin finden?**



Ein Beispiel für eine Musik-Geschichte:

- The Pudding, “Love Songs, RIP”