03 Research

2026-11-05

Ein Beispiel für eine Musik-Geschichte:

- The Pudding, “Love Songs, RIP”

Übung: Musik – US-Charts

Seit 1958 veröffentlicht das US-Magazin “Billboard” jeden Dienstag die “beliebtesten” Songs – basierend auf Verkäufen, Airplay und Streaming der jeweiligen Erfassungswoche. Alle Top-Titel hat Chris Dalla Riva für seinen Blog und sein Buch zusammengetragen und freundlicherweise als Google-Tabelle veröffentlicht: Billboard Hot 100 Number Ones Database.

Datenquellen



- Statistisches Bundesamt
- Statistische Landesämter
- govdata.de – Daten von Behörden, Kommunen, etc.

- Drucksachen Bundestag
- Google Dataset Search

Welche Daten dürfen wir benutzen?

“Open Data” ist ein feststehender Begriff seit vielen Jahren. In Deutschland gibt es dafür verschiedenste Regelungen, aber keine umfassende Verpflichtung, dass öffentliche Einrichtungen offene Daten verfügbar machen müssen. Dabei bedeutet das, dass man Daten frei nutzen kann, ohne weitere Einschränkungen:

> “Open means anyone can freely access, use, modify, and share for any purpose (subject, at most, to requirements that preserve provenance and openness).”
>
> https://opendefinition.org/

In der Praxis ist das in Deutschland oft anders umgesetzt und die datenveröffentlichende Stelle verlangt ihre Nennung. Das regelt die jeweilige Lizenz:

- “Gemeinfreiheit” CCO
- CC BY 4.0

Welche Daten dürfen wir benutzen?

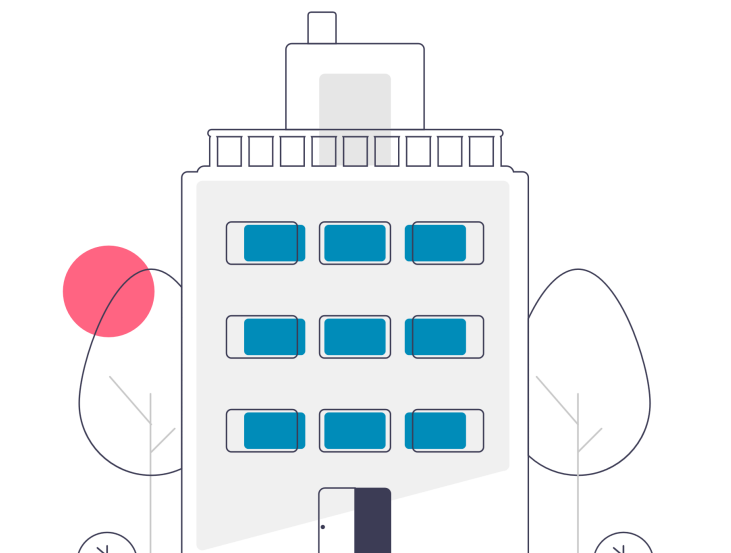
- “Datenlizenz Deutschland” BY, Zero

govdata.de rät zu CC-Lizenzen

Beispiel: “Freie Plätze sind rar: Die Lage in bayerischen Frauenhäusern”

2026: br24.de + CORRECTIV.Lokal → ndr.de, KATAPULT Sachsen, SWR…

2023: correctiv.org



→ Original-Website: frauenhaus-suche.de

Übung: Defekte Aufzüge / Rolltreppen in München



Website der Münchner Verkehrsgesellschaft MVG

Schritt 1: Was wünscht sich die Website-Betreiberin – was dürfen wir automatisiert auslesen? → robots.txt

Schritt 2: Wir schauen uns um: Was brauchen wir? → Developer-Tools öffnen (Rechtsklick oder Tastenkombination, je nach Browser + Betriebssystem) → *Tipp: Interessant ist oft “Network → XHR”*.

Was ist XHR?

Webseiten bestehen technisch aus HTML-Code. Hier haken “echte Programmierer” gern ein und korrigieren: HTML ist aber nur eine Auszeichnungssprache, das hat nichts mit Code zu tun.

Stimmt: HTML heißt HyperTextMarkupLanguage und kann vor allem verschiedene Elemente auf einer Website darstellen: Eine Überschrift auf dem höchsten Level wird markiert mit `<h1>` am Anfang und `</h1>` am Ende, eher eine Unterüberschrift mit `<h2>` und `</h2>`, eine Unterunterüberschrift mit `<h3>` und `</h3>` und so weiter…

Links sind oft interessant, die sind gekennzeichnet mit `<a href="https://example.com">Hier klicken</a>`. Hier klicken steht dann in Link-Formatierung auf der Website. Der Teil in Anführungszeichen hinter `href=` ist die URL, wo man hingeleitet wird.

Wenn jetzt eine Website was “können” soll, sich also anpassen oder Daten laden, dann nutzt man dafür JavaScript. Das ist eine Programmiersprache, die

Schritt 3: Wir schauen uns die reinen Daten im Rohformat “JSON” an: Schnittstelle

Schritt 4: Wir speichern uns die Daten ab, um sie lokal weiterzuverarbeiten.

R-Code ausklappen

```
library(jsonlite)
library(rrapply)

x <- fromJSON("https://www.mvg.de/.rest/mvgZoom/api/stations", simplifyVector = FALSE)

df <- x |>
  rrapply(how="melt")
```

Übung: Drogerie-Produkte

Wie viel kosten 100ml Sonnencreme im Durchschnitt und was ist der niedrigste Preis für 100ml Sonnencreme?



Code anzeigen

```
url <- "https://product-search.services.dmtech.com/de/search/crawl?query=Gesicht&allCategories.id=
020401&pageSize=30&searchType=editorial-search&sort=editorial_relevance&type=search-static&
enablePharmacy=true"
x <- fromJSON(url, simplifyVector = FALSE)

df <- x |>
  rrapply(how="melt")
```